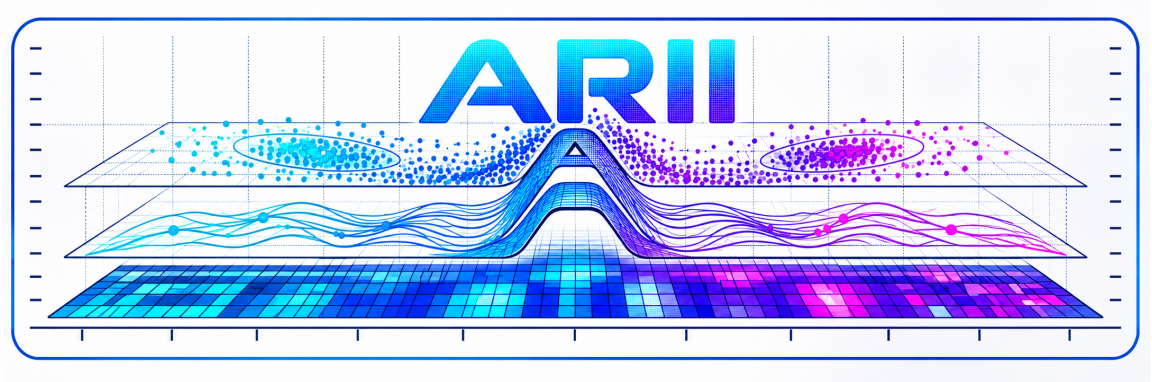


Documentación científica de Arii

Fundamentos, implementación, validación y limitaciones

Gabriel Anderson

Arii 1.1.0

Índice general

1. Alcance y principio de diseño **1**

2. Contrato de datos y preprocesamiento **2**
2.1. Matriz y metadatos . . . 2
2.2. Centrado y escalado . . . 2

3. Análisis de componentes principales **3**

4. PLS-DA y OPLS-DA **4**
4.1. PLS-DA . . . 4
4.2. Clasificación y error balanceado . . . 4
4.3. OPLS-DA . . . 5

5. Validación cruzada y selección **6**
5.1. Random subsets repetido . . . 6
5.2. Otros esquemas . . . 6
5.3. Selección de complejidad . . . 6

6. Resultados gráficos **7**
6.1. Scores y T^2 de Hotelling . . . 7
6.2. Loadings y gráfico de valores de carga . . . 7
6.3. Curvas de ROC y umbral . . . 7

7. Tests de permutaciones **8**

8. STOCSY **9**

9. Ejecución y reproducibilidad **10**

10. Limitaciones y uso responsable **11**

Capítulo 1

Alcance y principio de diseño

Arii implementa un flujo trazable para el análisis de una matriz ómica mediante PCA, PLS-DA y una representación OPLS-DA binaria. La aplicación separa tres niveles que no deben confundirse: el tratamiento técnico anterior a la matriz, el preprocesamiento estadístico aprendido por el modelo y la presentación de los resultados.

Los modelos base se calculan con mixOmics. Arii añade el contrato de datos, la validación agrupada, la selección de complejidad, diagnósticos, persistencia y una transformación ortogonal propia del espacio latente para la vista OPLS-DA. Esta última se documenta explícitamente porque no equivale a llamar a una función OPLS-DA nativa de *mixOmics*.

El documento describe qué calcula la versión 1.1.0, qué supuestos exige y qué conclusiones no permite. No reemplaza el criterio analítico específico de RMN, GC/LC-MS, proteómica, transcriptómica o genómica.

Capítulo 2

Contrato de datos y preprocesamiento

2.1 Matriz y metadatos

El núcleo trabaja con

$$\boldsymbol{X} \in \mathbb{R}^{n \times p}, \tag{2.1}$$

donde n es el número de muestras y p el número de variables. El eje ppm o los identificadores son metadatos de variables; clase e individuo son metadatos de muestras. El vector ppm nunca se incorpora como predictor.

El importador acepta las orientaciones *variables por muestras* y *muestras por variables*, pero el motor siempre recibe $\boldsymbol{X}$ con la forma anterior. La orientación se propone a partir de identificadores y dimensiones; que una propuesta sea sintácticamente plausible no garantiza que sea experimentalmente correcta. El usuario debe verificar nombres y dimensiones antes de modelar.

Arii distingue un perfil continuo de una tabla de características. En el primer caso existe un eje numérico y ordenado cuya vecindad tiene significado; en el segundo, el orden de las variables no implica continuidad. Esta distinción modifica la representación gráfica y la disponibilidad de STOCSY, pero no altera la forma matricial del ajuste.

Las matrices deben llegar con el tratamiento técnico pertinente ya realizado: normalización, alineamiento, corrección de deriva o lote, filtrado de calidad e imputación cuando correspondan. Un cero analítico, una ausencia de detección y un valor faltante no son equivalentes.

Cuando existe un identificador de individuo, éste define la unidad de remuestreo: sus réplicas permanecen juntas en entrenamiento o validación.

El motor rechaza valores ausentes, infinitos o no numéricos. Arii no imputa de forma automática porque la ausencia de detección, un cero analítico y un valor faltante tienen significados diferentes según la plataforma. También elimina del ajuste las variables con desviación estándar nula o numéricamente degenerada y registra cuántas fueron excluidas.

2.2 Centrado y escalado

Sea x_{ij} el valor de la variable j en la muestra i, $\bar{x}_j$ su media y s_j su desviación estándar muestral. Arii ofrece:

$$x_{ij}^{\text{Pareto}} = \frac{x_{ij} - \bar{x}_j}{\sqrt{s_j}}, \tag{2.2}$$

$$x_{ij}^{\text{UV}} = \frac{x_{ij} - \bar{x}_j}{s_j}, \tag{2.3}$$

$$x_{ij}^{\text{centrado}} = x_{ij} - \bar{x}_j. \tag{2.4}$$

En validación supervisada, $\bar{x}_j$ y s_j se estiman exclusivamente en el entrenamiento y se aplican al conjunto externo para evitar fuga de información.

Pareto reduce la influencia de las variables de gran escala sin igualarlas por completo; el escalado de varianza unitaria concede un peso comparable a todas las variables no constantes y puede amplificar ruido de pequeña varianza. La opción centrada conserva las diferencias originales de escala. Ninguna elección es universal: debe justificarse en relación con la plataforma y el objetivo.

Capítulo 3

Análisis de componentes principales

PCA aproxima la matriz centrada y escalada mediante

$$\boldsymbol{X} = \boldsymbol{T}\boldsymbol{P}^{\mathsf{T}} + \boldsymbol{E}, \tag{3.1}$$

donde $\boldsymbol{T}$ contiene los scores, $\boldsymbol{P}$ los loadings y $\boldsymbol{E}$ los residuos. Para a componentes:

$$\widehat{\boldsymbol{X}}_a = \boldsymbol{T}_a\boldsymbol{P}_a^{\mathsf{T}}. \tag{3.2}$$

Arii informa

$$\mathrm{RMSE}_{X,a} = \sqrt{\frac{1}{np}\sum_{i=1}^{n}\sum_{j=1}^{p}(x_{ij} - \widehat{x}_{ij,a})^2}, \tag{3.3}$$

$$R^2_X(a) = 1 - \frac{\mathrm{SSE}_{X,a}}{\mathrm{TSS}_X}. \tag{3.4}$$

Son métricas descriptivas calculadas sobre las observaciones de ajuste; no son rendimiento predictivo externo ni validan por sí solas el número de componentes.

Los scores son las coordenadas de las muestras en el espacio latente y los loadings describen la dirección de cada componente en el espacio de variables. La clase no interviene en el ajuste, aunque puede utilizarse para colorear la figura. Por tanto, una agrupación visual por clase es un resultado descriptivo y no una clasificación supervisada.

La cantidad máxima de componentes queda limitada por $\min(n-1, p)$. Arii informa la fracción de variación de $\boldsymbol{X}$ explicada por cada componente y su acumulado. Un aumento de R^2_X al añadir componentes es esperable incluso si esas direcciones recogen ruido; por eso no existe un umbral universal de varianza acumulada que valide el modelo.

Capítulo 4

PLS-DA y OPLS-DA

4.1 PLS-DA

PLS-DA relaciona $\boldsymbol{X}$ con una matriz indicadora $\boldsymbol{Y} \in \{0,1\}^{n\times g}$ mediante variables latentes que maximizan su covarianza. Arii ajusta `mixOmics::plsda` y asigna la clase mediante `max.dist`. Las respuestas continuas se conservan para R^2_Y, Q^2_Y, curvas de ROC y análisis de umbral.

La bondad de ajuste del modelo completo es

$$R^2_Y = 1 - \frac{\sum_i \|\boldsymbol{y}_i - \widehat{\boldsymbol{y}}_i\|^2}{\sum_i \|\boldsymbol{y}_i - \bar{\boldsymbol{y}}\|^2}, \tag{4.1}$$

y la capacidad predictiva interna utiliza predicciones externas:

$$Q^2_Y = 1 - \frac{\mathrm{PRESS}_Y}{\mathrm{TSS}_{Y,\mathrm{CV}}}. \tag{4.2}$$

Arii distingue siempre ajuste y CV. El primero aplica el modelo completo sobre las mismas observaciones que lo estimaron y es descriptivo y potencialmente optimista. El segundo agrega exclusivamente predicciones de muestras externas a cada ajuste y aproxima rendimiento interno fuera de fold.

En Q^2_Y, PRESS suma los errores externos. El denominador se centra respecto de las proporciones de clase aprendidas en cada entrenamiento, evitando usar información del conjunto externo para definir la referencia. Un valor alto no garantiza transferencia a otro estudio: las particiones siguen procediendo del mismo conjunto experimental.

4.2 Clasificación y error balanceado

$$\mathrm{Accuracy} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}(y_i = \widehat{y}_i), \tag{4.3}$$

$$\mathrm{BER} = \frac{1}{g}\sum_{k=1}^{g} \frac{\mathrm{FN}_k}{n_k}. \tag{4.4}$$

BER otorga el mismo peso a cada clase y es preferible cuando los tamaños de los grupos difieren.

Arii agrega una matriz de confusión con predicciones externas y calcula AUC one-vs-rest a partir de las respuestas continuas. La AUC macro es la media no ponderada de las AUC por clase, por lo que cada grupo contribuye por igual. Las métricas deben interpretarse conjuntamente: exactitud y AUC pueden ocultar una clase con baja sensibilidad, mientras que BER resume el error medio por clase.

4.3 OPLS-DA

Arii transforma un PLS-DA binario calculado con *mixOmics*. Para un modelo de a variables latentes, toma sus scores originales $\boldsymbol{T}_a$ y la respuesta continua predicha para la segunda clase. Tras centrar y normalizar esa respuesta, obtiene una base predictiva unitaria $\boldsymbol{q}_p$. El residuo de los scores es

$$\boldsymbol{T}_\perp = \boldsymbol{T}_a - \boldsymbol{q}_p \boldsymbol{q}_p^\top \boldsymbol{T}_a. \tag{4.5}$$

Una descomposición QR de $\boldsymbol{T}_\perp$ produce hasta $a-1$ direcciones ortogonales. Las bases se reescalan con la norma de los scores originales y los loadings se reestiman por mínimos cuadrados:

$$\boldsymbol{P}_{\text{rot}}^\top = (\boldsymbol{T}_{\text{rot}}^\top \boldsymbol{T}_{\text{rot}})^{-1} \boldsymbol{T}_{\text{rot}}^\top \boldsymbol{X}. \tag{4.6}$$

La rotación no reajusta la respuesta y no cambia R^2_Y, Q^2_Y, BER, confusión, ROC ni las predicciones. Las componentes ortogonales describen variación de $\boldsymbol{X}$ no asociada directamente con $\boldsymbol{Y}$ y no deben interpretarse como biomarcadores discriminantes.

La rotación se calcula por separado para cada complejidad candidata. Por ello, *Ortogonal 1* de un modelo de dos componentes no debe asumirse idéntica a *Ortogonal 1* de un modelo de tres. Esta implementación es una vista ortogonalizada y transparente del PLS-DA binario; no pretende reproducir de forma bit a bit un algoritmo propietario ni una implementación OPLS externa.

Capítulo 5

Validación cruzada y selección

5.1 Random subsets repetido

La configuración predeterminada ejecuta $R = 20$ repeticiones de $K = 5$ folds estratificados:

$$N_{\text{submodelos}} = R \times K = 100. \tag{5.1}$$

La fracción teórica por submodelo es 80/20, con variaciones por redondeo, balance de clase o agrupación de individuos. Cada unidad recibe una predicción externa por repetición.

La estratificación se realiza sobre unidades de remuestreo. Si existe un identificador biológico, todas sus réplicas comparten fold; si no existe, cada muestra es una unidad. Una clase debe contener al menos tantas unidades independientes como folds. Arii registra la fracción externa efectiva, que puede diferir del valor teórico cuando las unidades tienen distinto número de réplicas.

5.2 Otros esquemas

En **Monte Carlo**, cada iteración genera una partición aleatoria estratificada independiente; Arii registra su cobertura efectiva. **Leave-one-out** retira una unidad de remuestreo por submodelo, o el grupo completo si existen individuos. **Venetian blinds** distribuye sistemáticamente unidades ordenadas y sólo es defendible si el orden no codifica clase, lote o deriva de forma favorable.

Estas estrategias estiman propiedades distintas y no son intercambiables por conveniencia. Monte Carlo puede dejar algunas unidades menos representadas como externas; leave-one-out utiliza conjuntos de entrenamiento muy semejantes y puede presentar alta varianza; Venetian blinds depende de que el orden original no introduzca información espuria.

Toda operación aprendida a partir de $\boldsymbol{X}$ debe ocurrir dentro del fold. Arii aplica este principio al centrado, escalado y eliminación de variables constantes. El filtrado supervisado, la imputación o la corrección de lote hecha con el dataset completo antes de la validación pueden seguir produciendo fuga de información aunque el motor de Arii procese correctamente sus folds.

5.3 Selección de complejidad

Sea $\overline{e}_a$ el BER CV medio y SE_a su error estándar. Si $a_{\text{mín}}$ minimiza BER, Arii sugiere el menor a que satisface

$$\overline{e}_a \leq \overline{e}_{a_{\text{mín}}} + \mathrm{SE}_{a_{\text{mín}}}. \tag{5.2}$$

Es una selección exploratoria. Una estimación final sin sesgo requiere validación anidada o una cohorte externa.

Arii separa la **sugerencia** del **modelo actual**. Al terminar, la sugerencia inicial se adopta como modelo actual, pero el usuario puede elegir otra complejidad. Scores, loadings, confusión, ROC, exportación y permutaciones se refieren al modelo actual; las métricas de los candidatos permanecen para comparación. Esta distinción evita presentar una decisión manual como si fuera el resultado automático de la regla.

Capítulo 6

Resultados gráficos

6.1 Scores y T^2 de Hotelling

Para una representación bidimensional con $q = 2$ y n observaciones:

$$T^2_\alpha = \frac{q(n-1)}{n-q} F_\alpha(q, n-q). \tag{6.1}$$

La elipse representa una región global de scores; no es un intervalo por clase ni demuestra separación estadística.

La expresión se aplica a la proyección bidimensional visible y presupone una estructura aproximadamente elíptica. Un punto fuera del límite es una señal para revisión analítica, no evidencia automática de error ni autorización para excluir la muestra.

6.2 Loadings y gráfico de valores de carga

El Loading plot aplica un reescalado dependiente del preprocesamiento:

$$v_{jk}^{\text{Pareto}} = \sqrt{s_j}\, p_{jk}, \tag{6.2}$$

$$v_{jk}^{\text{UV}} = s_j\, p_{jk}, \tag{6.3}$$

$$v_{jk}^{\text{centrado}} = p_{jk}. \tag{6.4}$$

El eje vertical representa v_{jk} y el color el loading original con signo. En RMN el eje ppm se dibuja descendente. El signo de una componente latente es indeterminado y puede invertirse junto con sus scores sin alterar el modelo.

Para tablas de características Arii no conecta variables adyacentes con una curva, porque esa continuidad sería artificial. Para perfiles numéricos sí conserva la geometría del eje y, en RMN, lo dibuja en orden descendente.

6.3 Curvas de ROC y umbral

El AUC macro one-vs-rest es

$$\text{AUC}_{\text{macro}} = \frac{1}{g} \sum_{k=1}^{g} \text{AUC}_k. \tag{6.5}$$

El umbral exploratorio maximiza el índice de Youden

$$J(c) = \text{Sensibilidad}(c) + \text{Especificidad}(c) - 1. \tag{6.6}$$

No recalcula las métricas ni constituye un umbral clínicamente validado.

Las curvas se calculan por separado para el ajuste completo y para la media de las respuestas externas disponibles por muestra. Esta separación evita que una curva de ajuste optimista se presente como rendimiento validado.

Capítulo 7

Tests de permutaciones

Las etiquetas se permutan entre unidades intercambiables, manteniendo juntas las réplicas de un individuo y los tamaños de clase. Los folds se reutilizan; como $\boldsymbol{X}$ no cambia, también se reutilizan transformaciones permitidas.

La intercambiabilidad es un supuesto científico. Si existen bloques, pares, familias, centros o series temporales, la permutación debe respetar esa estructura. Informar un identificador de individuo protege réplicas del mismo sujeto, pero no modela automáticamente todos los diseños experimentales posibles.

Para una estadística cuyo valor alto favorece el modelo:

$$p_{\text{emp}} = \frac{1 + b}{B + 1}, \tag{7.1}$$

donde B es el número de permutaciones y b los valores nulos al menos tan extremos como el observado. La cola es superior para R^2_Y, Q^2_Y y AUC, e inferior para BER. La resolución mínima es

$$p_{\text{mín}} = \frac{1}{B + 1}. \tag{7.2}$$

La comparación residual y las gráficas frente a correlación de Y son diagnósticos complementarios; no sustituyen el p empírico.

La complejidad permanece fija en la del modelo actual. Esto responde a la pregunta: «¿un modelo con esta complejidad supera lo esperable bajo etiquetas intercambiadas?». No corrige el optimismo de haber elegido esa complejidad con los mismos datos. Una prueba que incluyera selección completa dentro de cada permutación respondería una pregunta diferente y tendría un coste mayor.

En la comparación residual, la unidad del contraste es la muestra y su referencia es el error medio de esa muestra bajo las permutaciones. Wilcoxon, la prueba de signos y el test t por aleatorización son diagnósticos relacionados; no deben tratarse como tres oportunidades independientes de declarar significancia.

Capítulo 8

STOCSY

Sea $\boldsymbol{x}_d$ la variable pivote y $\boldsymbol{x}_j$ cualquier otra variable:

$$\operatorname{cov}(\boldsymbol{x}_d, \boldsymbol{x}_j) = \frac{1}{n-1} \sum_{i=1}^{n} (x_{id} - \bar{x}_d)(x_{ij} - \bar{x}_j), \tag{8.1}$$

$$r_{dj} = \frac{\operatorname{cov}(\boldsymbol{x}_d, \boldsymbol{x}_j)}{s_d s_j}. \tag{8.2}$$

El perfil vertical representa covarianza y el color correlación. Arii usa todas las muestras del dataset cargado, no sólo las del modelo visible. Una asociación puede reflejar el mismo metabolito, covariación biológica, clase, lote o confusión; STOCSY no demuestra causalidad ni identifica por sí solo un compuesto.

La selección gráfica se asigna a la variable cuyo eje es más cercano al punto elegido. Si la variable pivote no presenta variación entre muestras, la correlación no está definida y Arii rechaza el cálculo. El uso del dataset completo aumenta el tamaño muestral, pero también significa que una selección de muestras del modelo no restringe STOCSY.

Capítulo 9

Ejecución y reproducibilidad

El mismo worker R y especificación JSON se utilizan localmente y en Slurm. Las validaciones y permutaciones independientes pueden distribuirse sin cambiar el contrato estadístico. La GPU no participa actualmente y Arii no la consulta.

El worker, la especificación JSON y el resultado forman el límite reproducible entre la interfaz y el motor. La ejecución paralela distribuye folds o permutaciones independientes; las semillas se derivan de forma determinista para que cambiar la cantidad de CPU no cambie la secuencia científica esperada.

Un proyecto `.arii` conserva configuración y resultados, pero referencia el dataset mediante ruta y SHA-256 en lugar de incorporarlo. Esta decisión evita duplicar matrices grandes o sensibles, a costa de exigir que el archivo original permanezca disponible y sin modificaciones.

Un informe reproducible debe conservar dataset y huella, muestras, clases e individuos, pretratamiento, centrado/escalado, modelo y complejidad, método CV, semilla, unidad de remuestreo, versiones, métricas externas, permutaciones, advertencias y validación independiente disponible.

Capítulo 10

Limitaciones y uso responsable

Los modelos con $p \gg n$ son especialmente vulnerables al sobreajuste. Ninguna separación visual, R^2_Y alto o prueba de permutación sustituye diseño experimental, control de calidad, plausibilidad biológica y validación externa.

Arii no realiza actualmente imputación, corrección de lote, selección dispersa de variables ni validación anidada. Si esos pasos se realizan antes de Arii usando información de clase o del dataset completo, el rendimiento CV puede quedar sesgado. El programa tampoco transforma automáticamente conteos, composiciones o datos de célula única a una geometría apropiada.

La vista OPLS-DA es una rotación documentada del PLS-DA binario de Arii. Debe citarse y describirse como tal; no corresponde atribuirle propiedades de una implementación OPLS distinta. Del mismo modo, el umbral de Youden, la elipse de Hotelling y STOCSY son ayudas exploratorias, no decisiones clínicas ni pruebas de identificación molecular.

Bibliografía

[1] Rohart F, Gautier B, Singh A, Lê Cao K-A. mixOmics: An R package for 'omics feature selection and multiple data integration. *PLoS Computational Biology*. 2017;13(11):e1005752. doi:10.1371/journal.pcbi.1005752.

[2] Wiklund S, Johansson E, Sjöström L, et al. Visualization of GC/TOF-MS-based metabolomics data for identification of biochemically interesting compounds using OPLS class models. *Analytical Chemistry*. 2008;80:115–122. doi:10.1021/ac0713510.

[3] Trygg J, Wold S. Orthogonal projections to latent structures (O-PLS). *Journal of Chemometrics*. 2002;16(3):119–128. doi:10.1002/cem.695.

[4] Westerhuis JA, Hoefsloot HCJ, Smit S, et al. Assessment of PLSDA cross validation. *Metabolomics*. 2008;4(1):81–89. doi:10.1007/s11306-007-0099-6.

[5] Cloarec O, Dumas M-E, Craig A, et al. Statistical total correlation spectroscopy: an exploratory approach for latent biomarker identification from metabolic ^{1}H NMR data sets. *Analytical Chemistry*. 2005;77:1282–1289. doi:10.1021/ac048630x.